

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ

ВЫСШЕГО ОБРАЗОВАНИЯ

«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ЛАБОРАТОРНАЯ (ПРАКТИЧЕСКАЯ) РАБОТА № 1

по дисциплине «Машинное обучение»

на тему «Библиотеки Python для машинного обучения. Работа с данными»

Выполнил:

Студент Качуков К.Д.

Группа ИПБП41

Проверил:

Дольников Максим Генадьевич

Ростов-на-Дону

2026 г.

1. Цель и задачи работы

Цель работы — освоить основные библиотеки Python, применяемые при работе с данными и машинном обучении: NumPy, Pandas, Matplotlib, SciPy, scikit-learn, TensorFlow, Keras и PyTorch; получить практические навыки чтения и записи табличных данных, предобработки, статистического анализа, масштабирования, тензорных вычислений и обработки изображений.

В ходе работы требуется реализовать операции чтения и сохранения данных, обнаружение и исправление проблем в датасете, функции масштабирования и обратного преобразования, статистические расчёты и проверку гипотез, спектральный анализ, интерполяцию, работу со скользящими окнами, тензорами, разреженными матрицами, PCA и цветным изображением.

2. Исходные данные и программная среда

Работа выполнена в среде PyCharm на языке Python. Проект построен модульно: отдельные файлы отвечают за ввод-вывод, загрузку и контроль качества данных, предобработку, статистический анализ, масштабирование, скользящие окна, тензорные вычисления, матричные операции и обработку изображения.

```
VARIANT_COLUMNS = ["x1", "x2", "y"]
SEED = 42
```

Исходный файл dataset_var2.csv содержит 500 строк и 7 столбцов: id, timestamp, category, x1, x2, x3, y. Для вычислений согласно варианту используется копия столбцов x1, x2 и y; исходный CSV не изменяется.

Параметр	Значение
Размер исходного датасета	500 × 7
Столбцы варианта	x1, x2, y
Некорректные значения x1	2 значения «ошибка»
Пропуски x2	10 значений NaN
Итоговый тип столбцов	float64
Seed	42

Первые строки исходных данных приведены в таблице 1.

id	category	x1	x2	y
1	A	1.301741289398798	-1.2546	4.4270
2	A	1.6115111967268527	4.5071	0.3746
3	B	0.13200414906576663	2.3199	-0.1215
4	A	-0.6034178703461834	0.9866	-3.1531
5	C	0.6599721429391164	-3.4398	3.5460
6	B	-0.4277153697521061	-3.4401	4.1735

Таблица 1 — Фрагмент исходного датасета

3. Выполнение лабораторной работы

3.1. Задания 1–13. Считывание, контроль качества и предобработка

В проекте реализовано чтение файлов .xlsx, .csv, .txt и .mat, а также запись таблиц в эти форматы с сохранением заголовков. Имена создаваемых файлов включают дату и время. Графики сохраняются в PNG по тому же правилу.

При первичной проверке обнаружены две группы проблем: столбец x1 имел тип object из-за двух строковых значений «ошибка», а в x2 обнаружено 10 пропусков. Столбец y изначально был числовым и не содержал пропусков.

Проверка	x1	x2	y
Исходный тип	object	float64	float64
Пропуски	0	10	0
Некорректные числовые значения	2	0	0
Тип после обработки	float64	float64	float64
Пропуски после обработки	0	0	0

Автоматический сценарий очистки соответствует предусмотренным методичкой действиям: некорректные значения преобразуются в NaN, затем пропуски заполняются средним значением по столбцу. Для демонстрации преподавателю в проекте также предусмотрено интерактивное меню обработки.

Действие	Результат
x1: приведение к числу	2 некорректных значения преобразованы в NaN
x1: заполнение пропусков	среднее = 12.562419
x2: заполнение пропусков	среднее = -0.009526
Контроль после очистки	NaN = 0, несовпадений типов = 0

После очистки DataFrame преобразован в массив NumPy размерности 500 × 3. Для воспроизводимости seed=42 фиксируется для всех доступных генераторов случайных чисел.

Реализованы три варианта масштабирования: MinMax в диапазоне [0; 1], MinMax в произвольном диапазоне (в работе [-1; 1]) и стандартизация z-score. Для каждого способа сохраняются параметры, необходимые для обратного преобразования. Максимальные ошибки восстановления находятся на уровне машинной точности.

Метод	Макс. ошибка собственного метода	Макс. ошибка sklearn
MinMax [0;1]	7.105e-15	7.105e-15
MinMax [-1;1]	7.105e-15	7.105e-15
z-score	4.441e-15	4.441e-15

Разбиение данных выполнено в соотношении 70% / 15% / 15%: train — 350 строк, validation — 75 строк, test — 75 строк.

3.2. Задания 14–21. Визуализация и статистический анализ

Для исходных столбцов построены графики значений, нормализованные гистограммы и эмпирические функции распределения. На рисунке 1 показаны исходные ряды x1, x2 и y.



Рисунок 1 — Исходные данные x1, x2 и y

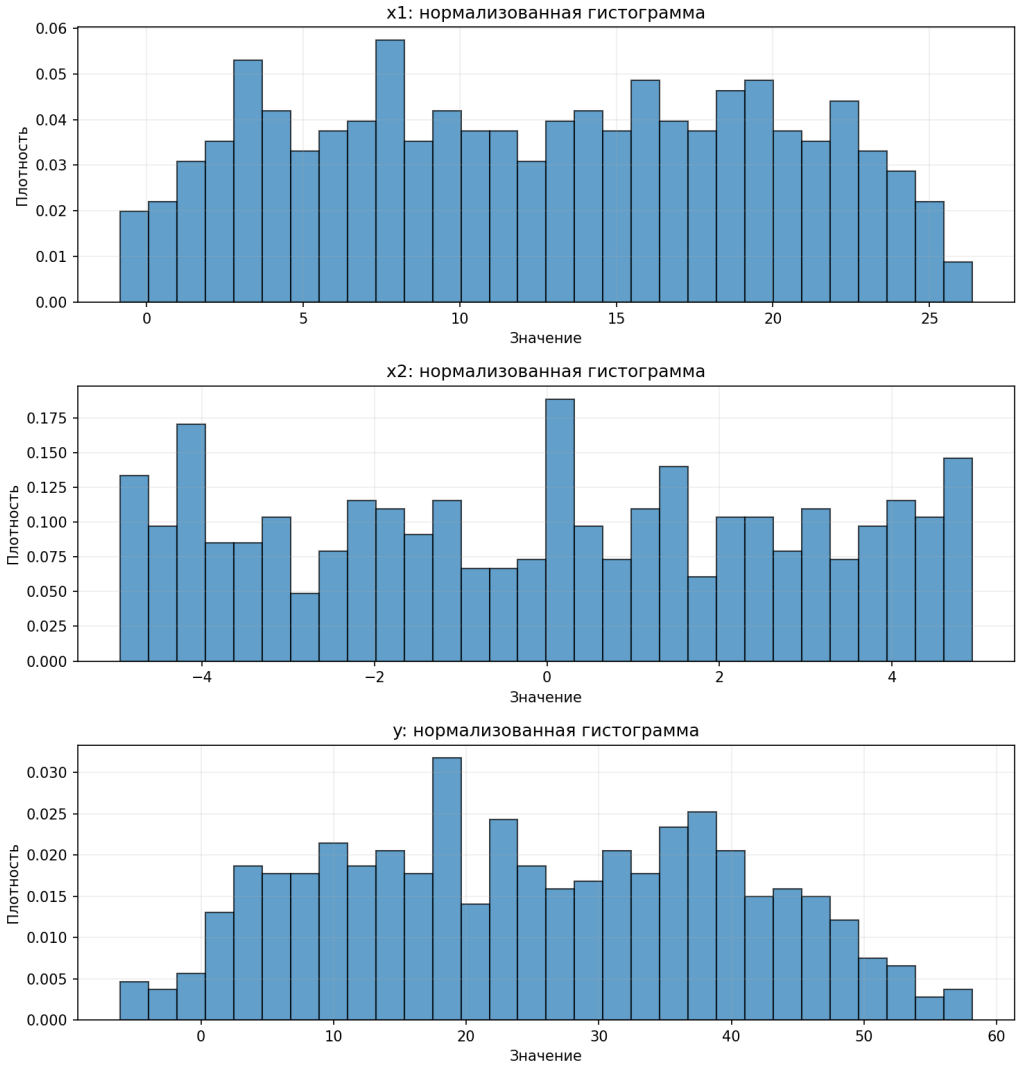


Рисунок 2 — Нормализованные гистограммы распределений

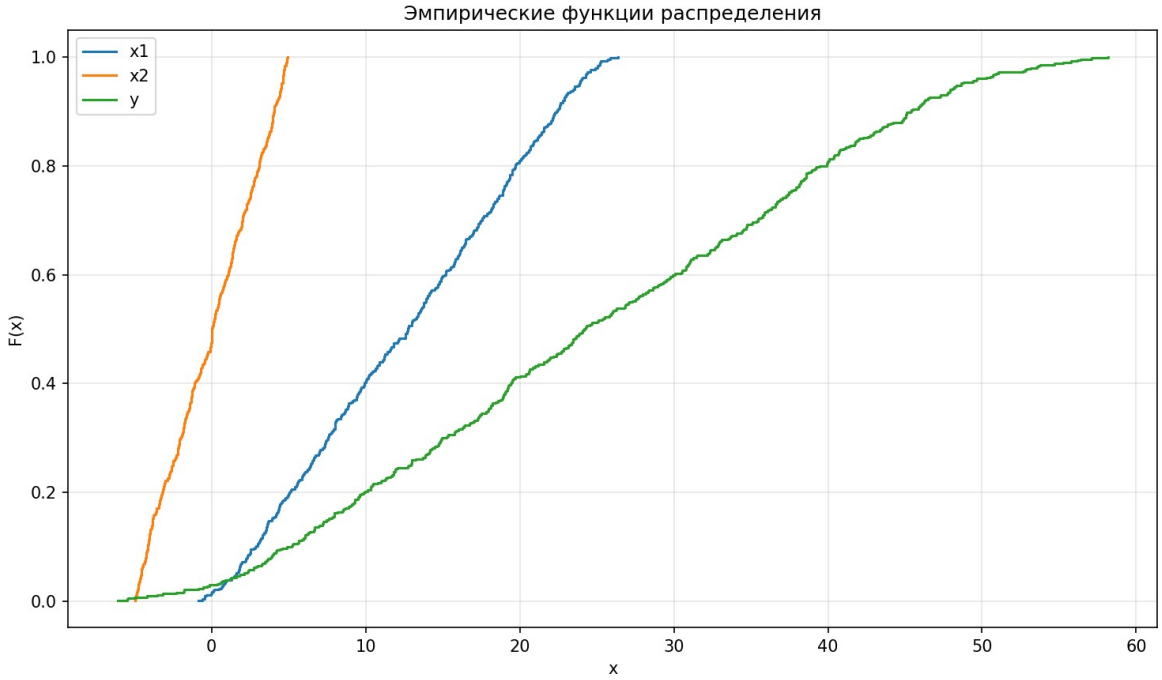


Рисунок 3 — Эмпирические функции распределения

Выборочные характеристики, рассчитанные средствами NumPy, Pandas и SciPy, приведены в таблице 2. Значения среднего и медианы близки для x1 и x2; столбец y имеет существенно большую дисперсию.

Столбец	Среднее	Выб. дисперсия	Медиана	Мода
x1	12.5624	51.8544	12.7223	12.5624
x2	-0.0095	8.7190	0.0291	-0.0095
y	25.0615	226.9302	24.2277	-6.0984

Таблица 2 — Основные выборочные характеристики

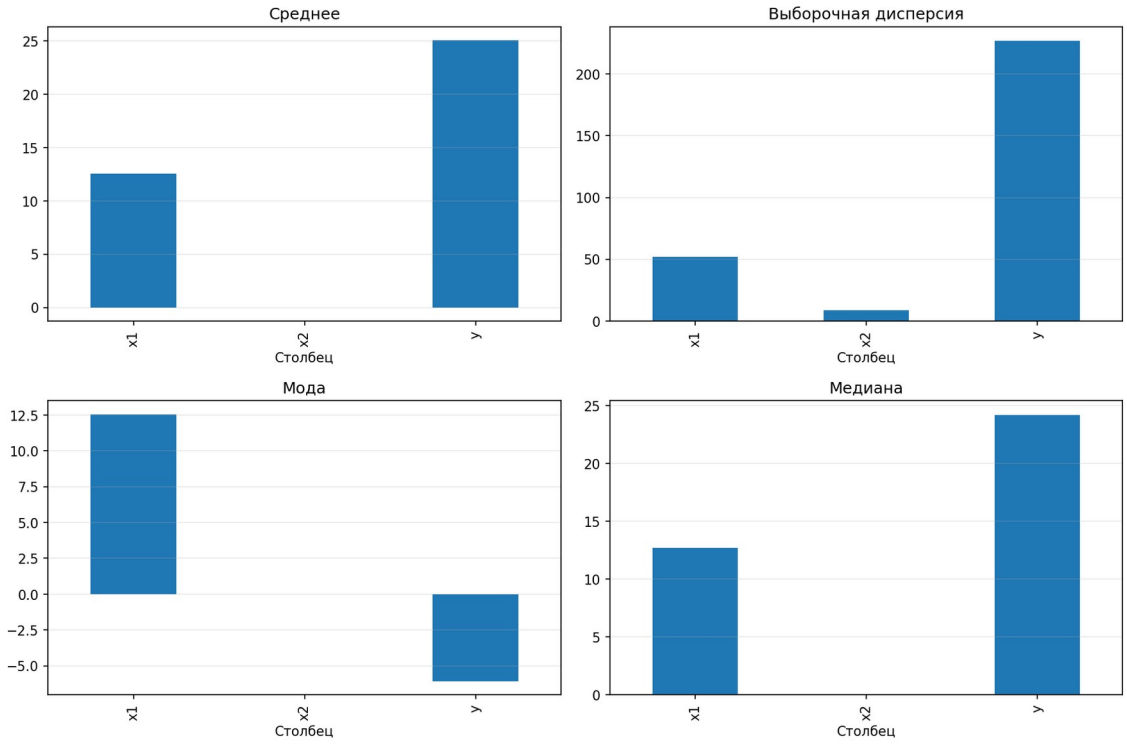


Рисунок 4 — Графическое сравнение статистических характеристик

Столбец	Среднее	95% ДИ среднего	Дисперсия	95% ДИ дисперсии
x1	12.5624	[11.9297; 13.1951]	51.8544	[45.9769; 58.9418]
x2	-0.0095	[-0.2690; 0.2499]	8.7190	[7.7307; 9.9107]
y	25.0615	[23.7379; 26.3851]	226.9302	[201.2088; 257.9469]

Таблица 3 — Доверительные интервалы при α = 0,05

Коэффициенты корреляции показывают сильную положительную линейную связь между x1 и y (r≈0,949), слабую связь между x1 и x2 и умеренную отрицательную связь между x2 и y.

	x1	x2	y
x1	1.000	0.064	0.949
x2	0.064	1.000	-0.219
y	0.949	-0.219	1.000

Таблица 4 — Матрица корреляции

Пара	r Пирсона	p-value	Значима при α=0,05
x1–x2	0.0643	0.151	нет
x1–y	0.9488	2.568e-251	да
x2–y	-0.2191	7.513e-07	да

Таблица 5 — Проверка значимости коэффициентов корреляции

3.3. Задания 22–33. Корреляционные, дифференциальные и спектральные операции

Для пар столбцов вычислена взаимная корреляция в зависимости от сдвига. Также рассчитаны численные производные и градиенты, свёртки, скалярные и векторные произведения, L1- и L2-нормы.

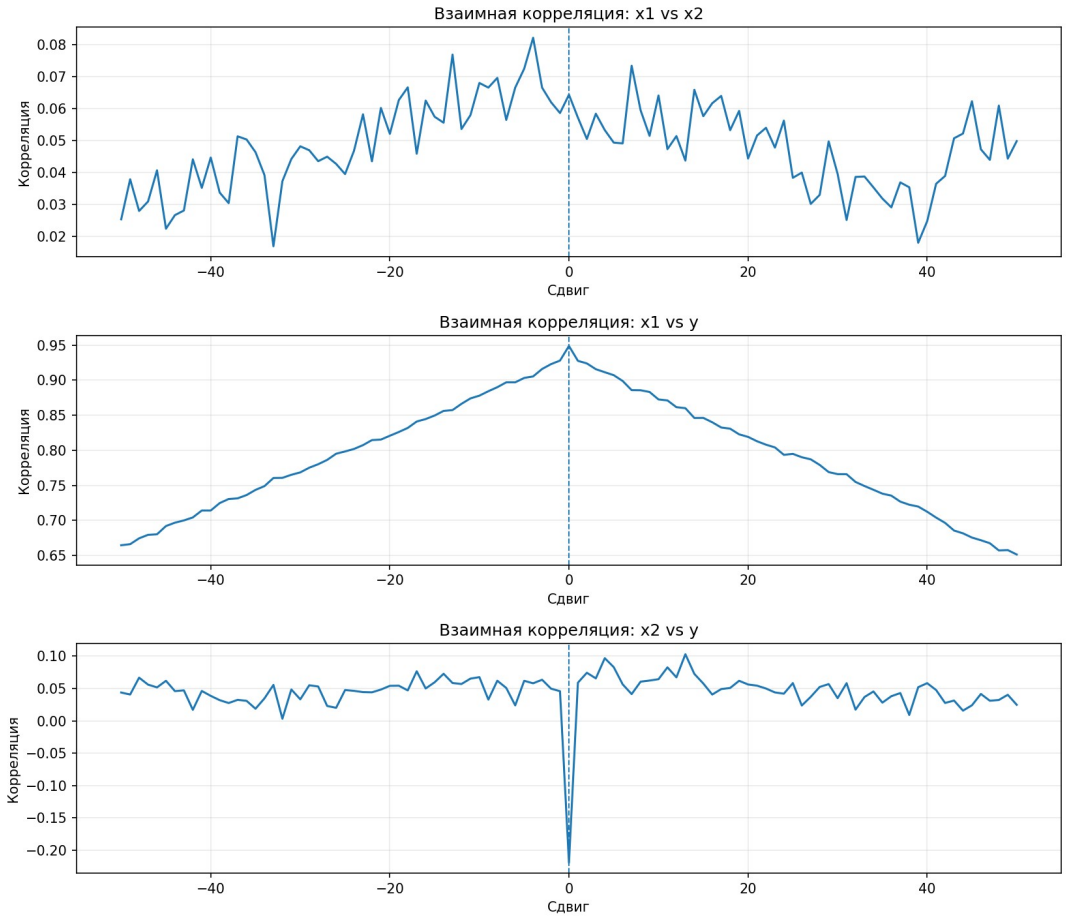


Рисунок 5 — Взаимная корреляция столбцов при различных сдвигах

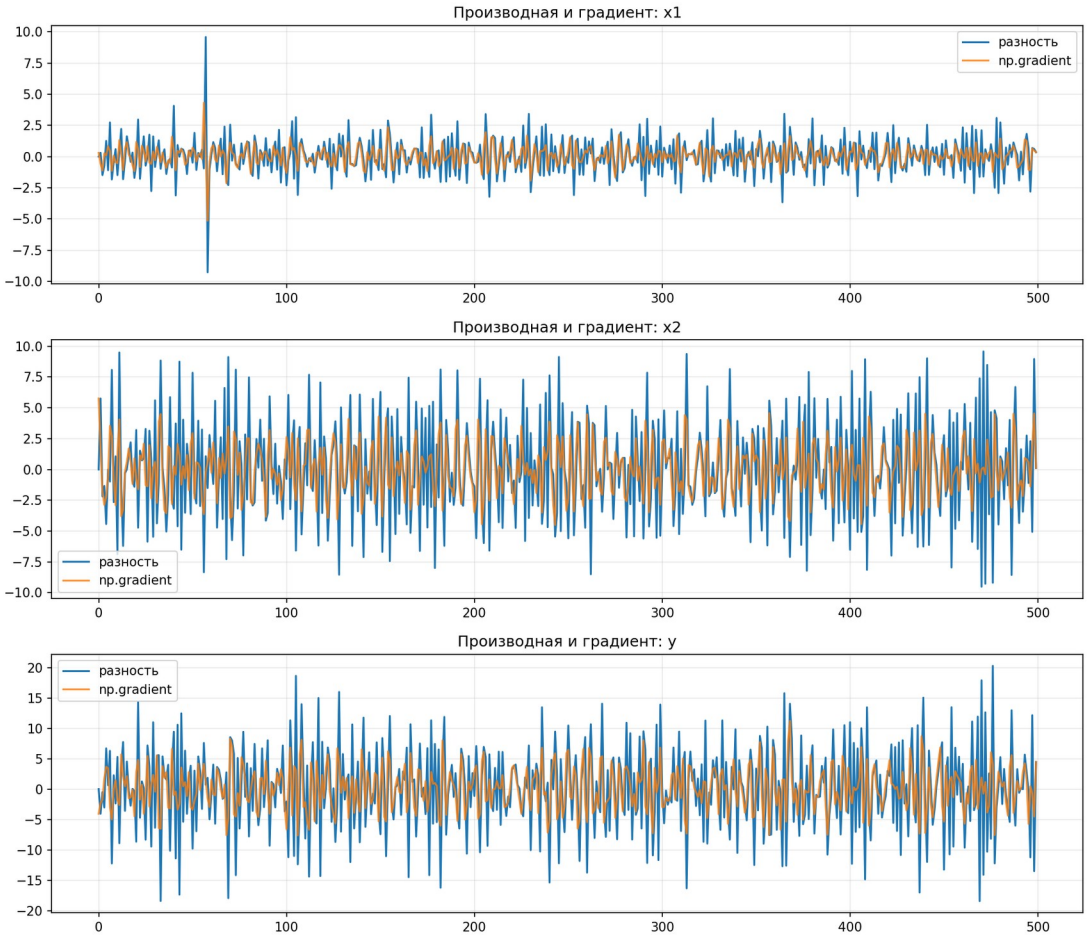


Рисунок 6 — Численные производные и градиенты

Столбец	L1-норма	L2-норма
x1	6287.393	323.701
x2	1270.878	65.961
y	12615.336	653.664

По заданию 27 для первого столбца проверена гипотеза о равномерном распределении, а для второго — о нормальном. Для x1 критерий Колмогорова–Смирнова дал $p=0{,}1020$, поэтому при $\alpha=0{,}05$ нет оснований отвергать гипотезу о равномерности. Для x2 $p=0{,}0217$ по Колмогорову–Смирнову и $p\approx 4{,}40\cdot 10^{-12}$ по Шапиро–Уилку, поэтому гипотеза о нормальности отвергается.

Проверка	Статистика	p-value	Вывод
x1: равномерное распределение	0.0542	0.1020	H0 не отвергается
x2: нормальное, K-S	0.0669	0.0217	H0 отвергается
x2: нормальное, Shapiro-Wilk	0.9492	4.398e-12	H0 отвергается

Для каждого столбца построены спектрограмма, периодограмма и амплитудно-частотная характеристика по преобразованию Фурье.

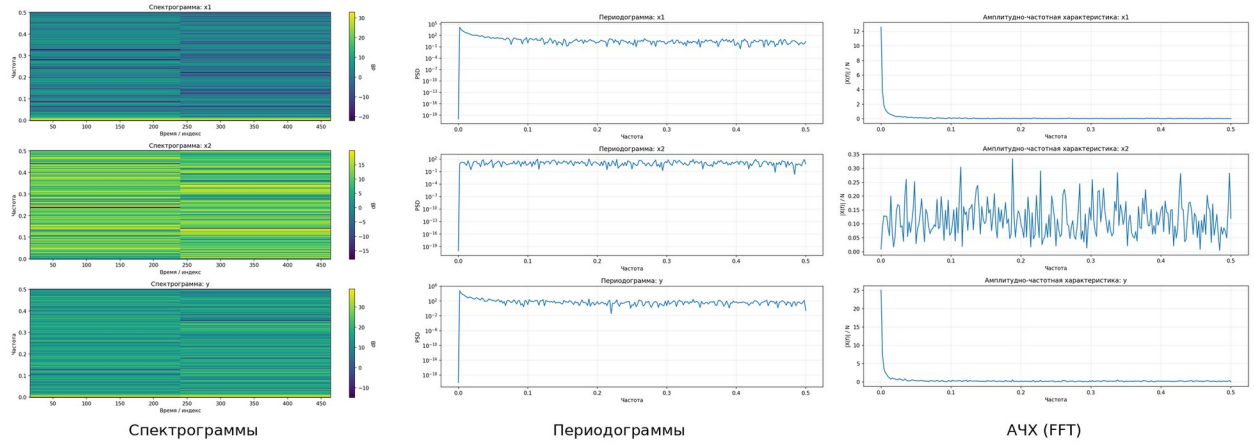


Рисунок 7 — Результаты спектрального анализа (задания 28–30)

В заданиях 31–32 выполнены кубическая интерполяция и интерполяция сплайнами. Интерполированные кривые проходят через исходные точки и обеспечивают гладкое восстановление промежуточных значений.

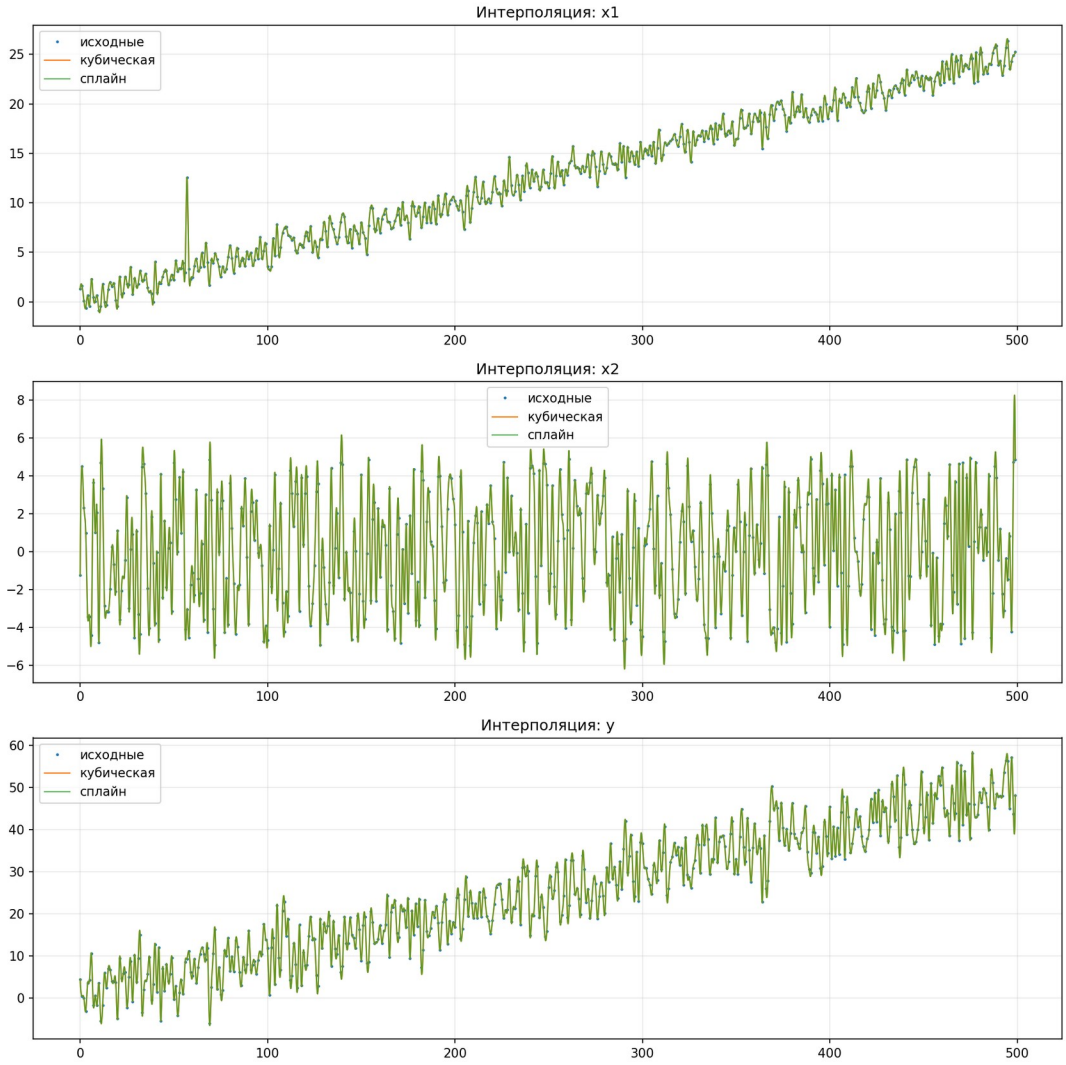


Рисунок 8 — Кубическая и сплайн-интерполяция

Для каждого столбца сформированы бинарные маски: положительные, отрицательные, нулевые элементы и значения в интервале [-1;1].

Столбец	Положительные	Отрицательные	Нулевые	[-1;1]
x1	492	8	0	19
x2	253	247	0	95
y	485	15	0	9

3.4. Задания 34–37. Сравнение масштабирования и скользящие окна

Результаты собственных реализаций MinMax и z-score сопоставлены с MinMaxScaler и StandardScaler из scikit-learn. Совпадение проверяется функцией

np.allclose; обратное преобразование даёт ошибки порядка 10^{-15}, то есть отличия определяются только вычислениями с плавающей точкой.

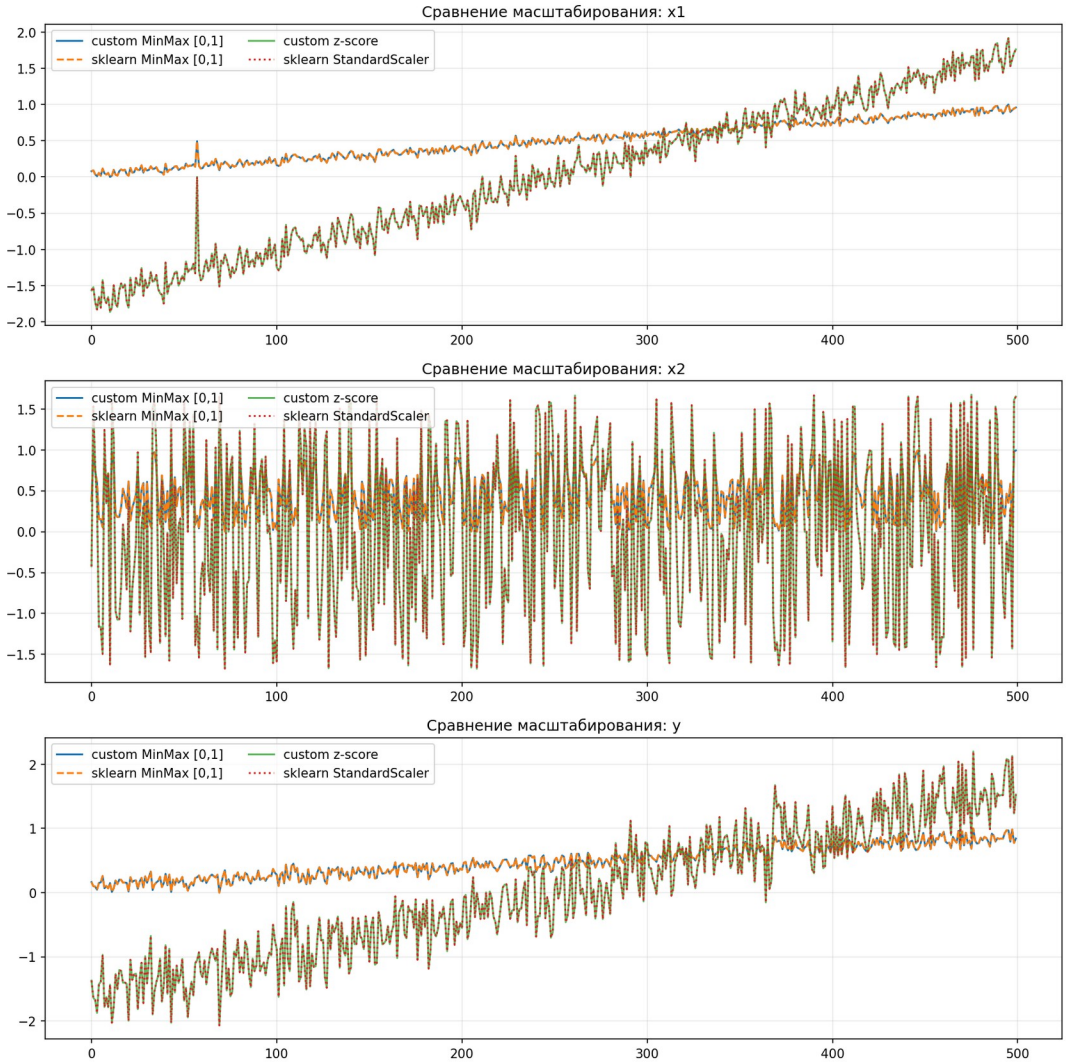


Рисунок 9 — Сравнение собственного масштабирования со scikit-learn

Для первого столбца сформированы скользящие окна шириной 5. При 500 исходных значениях получено 496 окон и 496 значений скользящего среднего.

3.5. Задания 38–45. Тензорные вычисления

Исходный массив размерности 500 × 3 преобразуется в тензоры TensorFlow и PyTorch. Для операции AXW+B размеры случайных тензоров выбираются согласованно, чтобы результат имел размер 5 × 4. В PyTorch тестовый запуск подтвердил форму исходного тензора [500, 3] и результата AXW+B [5, 4].

Матрицы T, P и Q размерности 3 × 10 создаются средствами NumPy и преобразуются в тензоры Keras и PyTorch. Реализована операция V=(sin(T)-exp(P))Q по формуле задания; для PyTorch получен тензор V размерности 3 × 10.

Объект	Размерность
X (PyTorch)	500 × 3
AXW+B (PyTorch)	5 × 4
T, P, Q	3 × 10
V (PyTorch)	3 × 10
X / AXW+B (TensorFlow)	реализовано в проекте; выполняется при наличии TensorFlow
V (Keras)	реализовано в проекте; выполняется при наличии TensorFlow/Keras

3.6. Задания 46–49. Разреженные матрицы, многомерный массив F и PCA

Средствами SciPy сгенерирован разреженный массив размерности 100000 × 100000 с 100000 ненулевых элементов. Для случайной матрицы 100 × 100 найдена обратная; максимальная ошибка произведения $M \cdot M^{-1}$ относительно единичной матрицы составила около $1{,}99 \cdot 10^{-14}$.

В задании 48 исходный массив достроен до многомерного массива F. Для каждого из трёх признаков хранятся исходное значение, три масштабированных представления и четыре бинарные маски. Итоговая форма F — 500 × 3 × 8.

Канал F	Содержание
1	original
2	minmax_0_1
3	minmax_-1_1
4	zscore
5	mask_positive
6	mask_negative
7	mask_zero
8	mask_interval_-1_1

В задании 49 сформирован Pipeline scikit-learn, объединяющий масштабирование и PCA. Перебраны варианты набора признаков и MinMaxScaler/StandardScaler. Лучшим по validation log-likelihood оказался набор scaled_representations с MinMaxScaler и двумя главными компонентами.

Набор признаков	Scaler	Признаков	PC	Val log-likelihood	Expl.var (2D)
scaled_representations	MinMaxScaler	9	2	15.365	0.9973
all_F_channels	MinMaxScaler	24	2	11.292	0.7943
original	MinMaxScaler	3	2	1.339	0.9973
scaled_representations	StandardScaler	9	2	2.901	0.9969
original_plus_masks	MinMaxScaler	15	2	3.348	0.7325
original	StandardScaler	3	2	-2.684	0.9969
all_F_channels	StandardScaler	24	2	-25.622	0.6826
original_plus_masks	StandardScaler	15	2	-18.678	0.5612

Таблица 6 — Сравнение вариантов Pipeline scaling + PCA

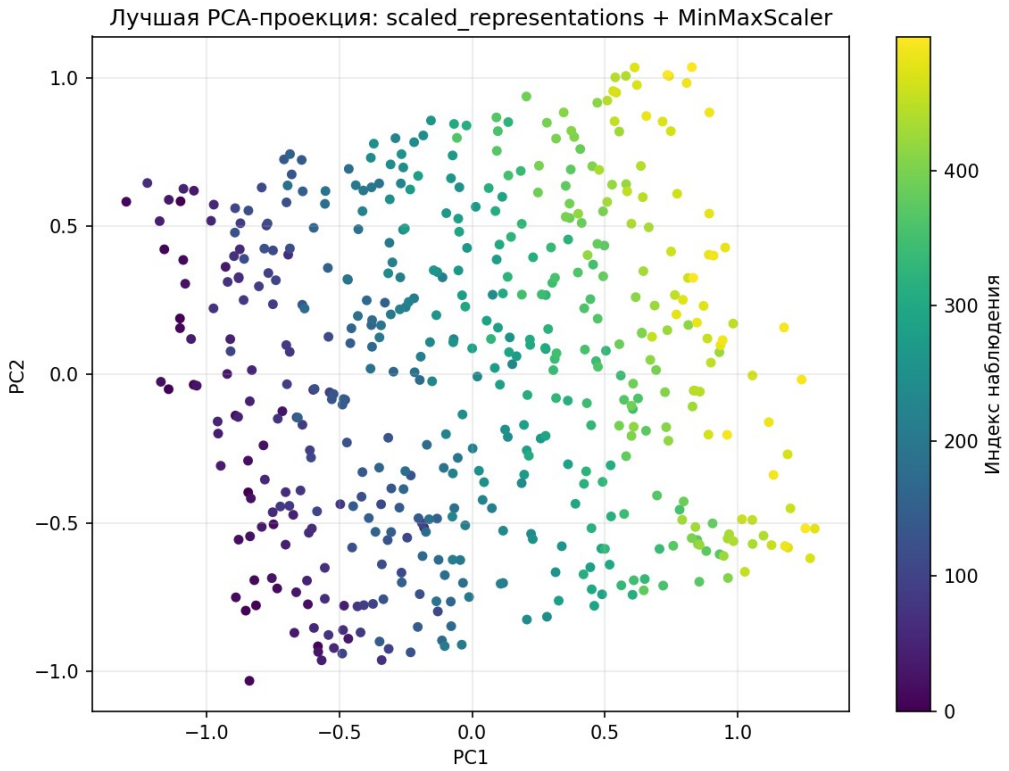


Рисунок 10 — Лучшая двумерная PCA-проекция

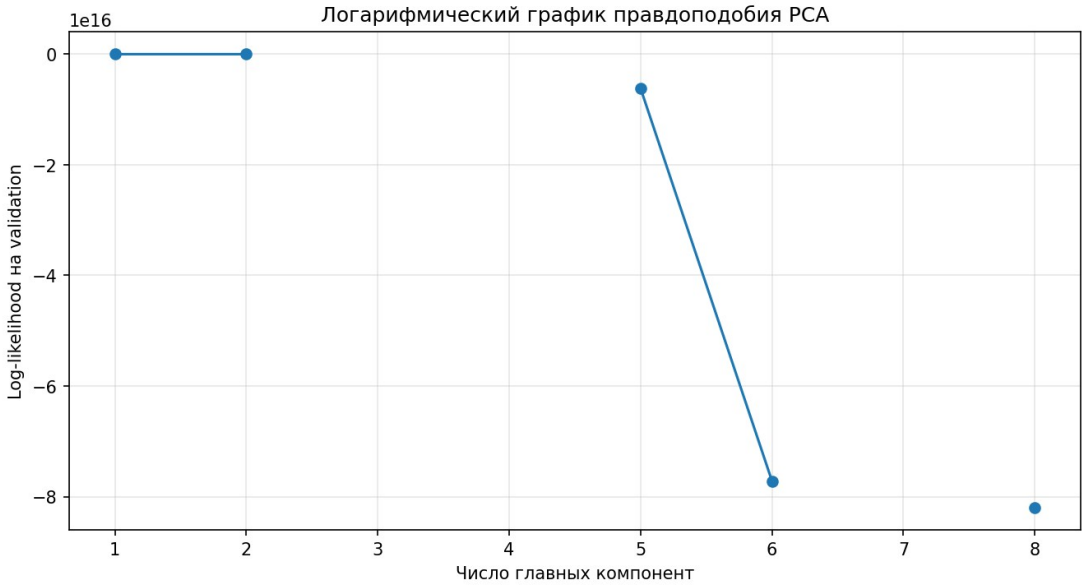


Рисунок 11 — Логарифмическое правдоподобие в зависимости от числа компонент

3.7. Задание 50. Обработка цветного изображения средствами SciPy

В проект включено цветное изображение sample_image.png размерности 320 × 480 × 3. Выполнено разделение RGB-каналов, поворот на 40°, преобразование в оттенки серого, построение гистограммы, разбиение изображения на три диапазона яркости, построение чёрной круговой рамки, добавление шума, гауссово размытие, sharpening и PCA.

По гистограмме получены пороги яркости 101 и 154. Для PCA изображения доли объяснённой дисперсии первых двух компонент составили 0.4137 и 0.3046.

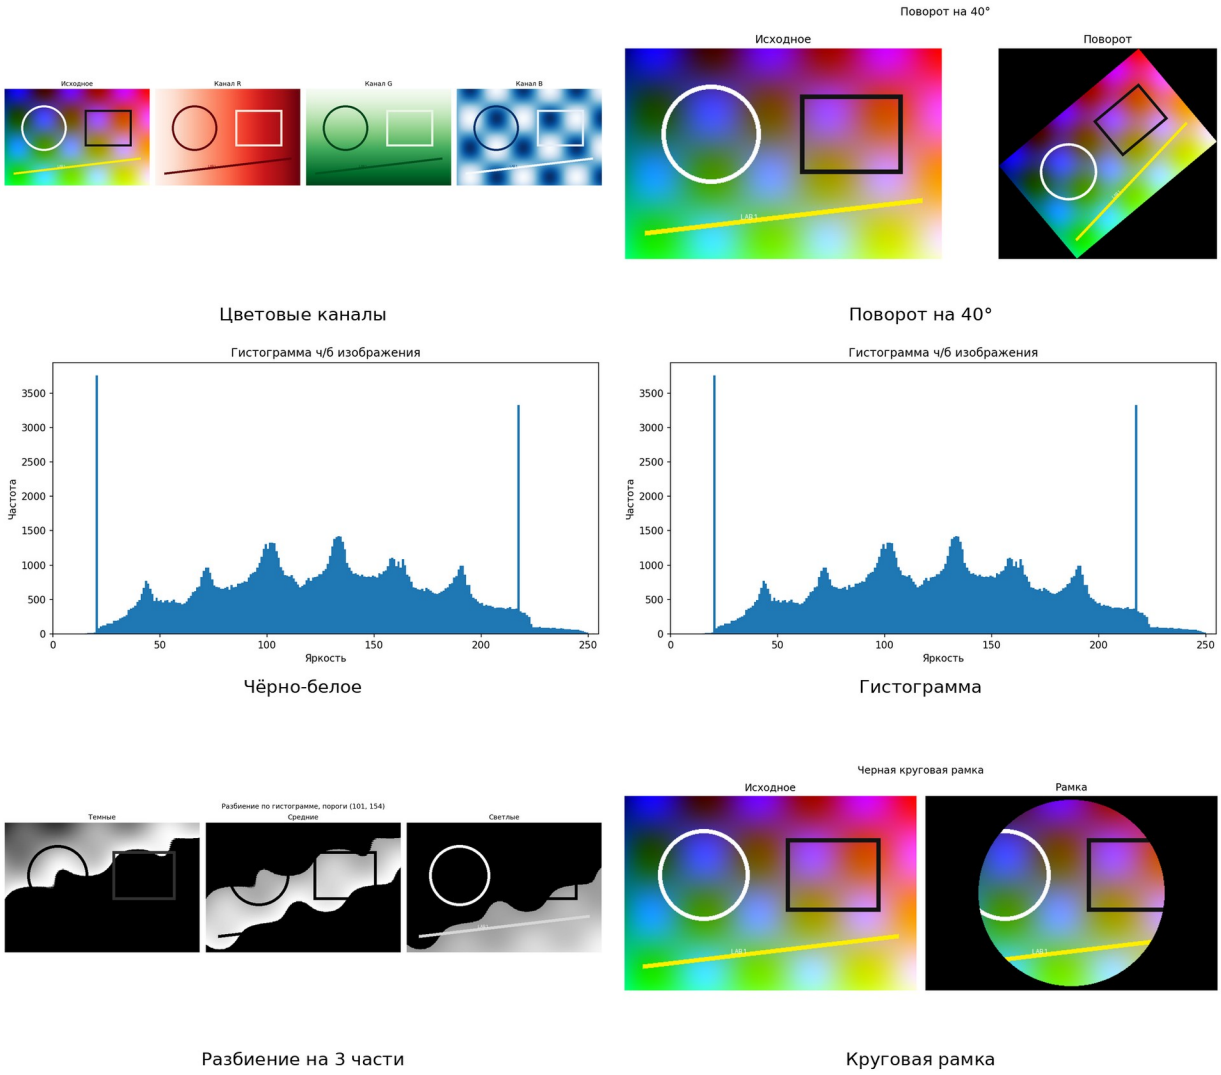


Рисунок 12 — Основные операции обработки изображения: часть 1

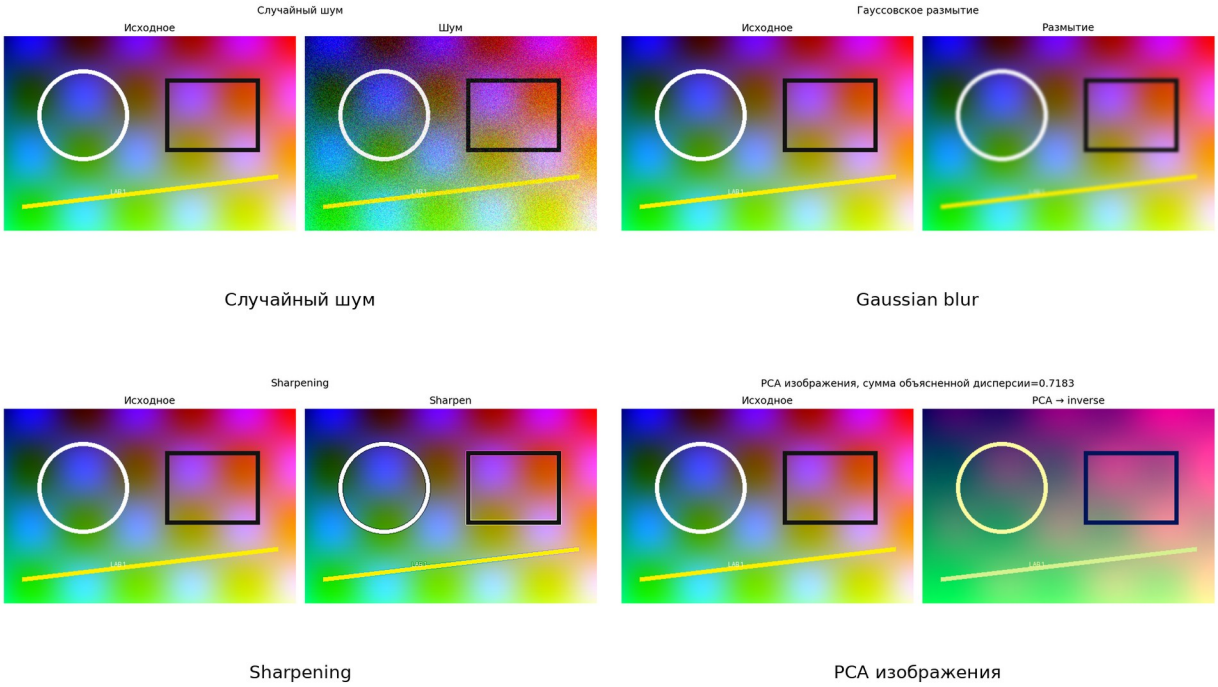


Рисунок 13 — Основные операции обработки изображения: часть 2

4. Структура проекта и запуск

Проект подготовлен для открытия в PyCharm. Точка входа — main.py. Результаты каждого задания автоматически сохраняются в каталог output с отметкой даты и времени. Исходный датасет находится в data/dataset_var2.csv.

```
lab1_variant2/
├── data/
│   ├── dataset_var2.csv
│   └── sample_image.png
├── output/
├── src/
│   ├── config.py
│   ├── io_utils.py
│   ├── data_loader.py
│   ├── preprocess.py
│   ├── stats_analysis.py
│   ├── scaling.py
│   ├── windows.py
│   ├── tensors.py
│   ├── matrix_ops.py
│   └── image_proc.py
├── main.py
└── requirements.txt
```

Обычный запуск выполняет лабораторную полностью в автоматическом режиме. Для демонстрации интерактивного меню задания 8 можно передать аргумент --interactive-cleaning; для сокращённого вывода таблицы — --brief.

5. Вывод

В лабораторной работе реализован полный цикл работы с данными средствами основных библиотек Python: загрузка и сохранение нескольких форматов, контроль качества и предобработка, преобразование Pandas DataFrame в NumPy, масштабирование и восстановление масштаба, разбиение выборки, статистический и корреляционный анализ, проверка гипотез, спектральные методы, интерполяция, скользящие окна, тензорные и матричные операции, построение многомерного представления признаков, PCA и обработка цветного изображения.

Для dataset_var2 выявлены и устранены две текстовые ошибки в x1 и десять пропусков в x2. После очистки получен числовой массив 500 × 3 без пропусков. Наиболее выраженная статистическая связь наблюдается между x1 и y ($r \approx 0{,}949$, $p \ll 0{,}05$). Собственные функции масштабирования совпадают с реализациями scikit-learn с точностью до погрешности вычислений с плавающей точкой. В PCA лучшим оказался вариант масштабированных представлений с MinMaxScaler: две компоненты объясняют около 99,73% дисперсии. Поставленные задачи лабораторной работы выполнены.

Приложение А. Соответствие модулей заданиям

Файл	Назначение
src/config.py	seed, пути, служебные функции сохранения
src/io_utils.py	задания 1–3
src/data_loader.py	задания 4–7
src/preprocess.py	задания 8–13
src/stats_analysis.py	задания 14–33
src/scaling.py	задания 34–35
src/windows.py	задания 36–37
src/tensors.py	задания 38–45
src/matrix_ops.py	задания 46–49
src/image_proc.py	задание 50
main.py	последовательный запуск всей работы